


강화학습의 골디락스 존: PPO가 산을 오르는 방법

2017년 OpenAI의 논문이 인공지능의 학습 방식을
어떻게 영원히 바꾸었는가

원논문: Proximal Policy Optimization Algorithms (John Schulman et al.)



인공지능은 시행착오라는 지도를 그리며 산을 오릅니다

강화학습(Reinforcement Learning)은
AI가 환경과 상호작용하며 '보상(Reward)'을
극대화하는 행동 방식을 스스로 깨우치는
과정입니다.

목표는 단순합니다:
가장 높은 산봉우리(최적의 정책)를 찾는 것.


하지만 짙은 안개 속에서 지형을 모른 채
발걸음을 내디뎌야 하는 치명적인 어려움이
있습니다.





**단 한 번의 무리한 발걸음이
모든 기억을 파괴할 수 있습니다**

AI가 새로운 데이터를 바탕으로 학습 방향을 크게 틀어버리면, 기존에 학습했던 좋은 행동 패턴(Policy)마저 붕괴되는 현상이 발생합니다. 이를 막기 위해 AI의 '보폭(Update size)'을 조절해야 하지만, 이것은 결코 쉬운 문제가 아닙니다.



과거의 방식 1: 한 번 쓰고 버려지는 데이터의 낭비


Standard Policy Gradient

한 번의 데이터 샘플링으로 단 한 번의
경사 상승(Gradient Update)만 수행합니다.

The Flaw

안전하게 조금씩 이동할 수는 있지만, 데이터 소모가
극심하고 학습 속도가 비효율적으로 느립니다
(열악한 샘플 복잡도).

너무 느리고 낭비가 심한 접근법.



과거의 방식 2: 완벽하지만 너무 무겁고 복잡한 안전망


TRPO (Trust Region Policy Optimization)

AI가 안전 구역을 벗어나지 못하도록 엄격한 수학적 제약을 가합니다.

The Flaw

학습은 안정적이지만, 구조가 지나치게 복잡하고 계산 비용(연산량)이 기하급수적으로 증가합니다.

너무 무겁고 구현하기 어려운 접근법.



완벽한 균형을 찾은 새로운 이정표, PPO의 등장


2017년, John Schulman과 연구진은 두 가지 과거 방식의 장점만을 결합한 PPO (Proximal Policy Optimization)를 발표했습니다.

TRPO의 안전성 유지


뛰어난 단순성 확보

핵심 개념 1: 주변 지형을 단순화한 '대리 목적 함수'

실제 지형 (True Objective)




대리 목적 함수 (Surrogate Objective)




전체 산의 지형을 한 번에 계산하는 것은 불가능에 가깝습니다. PPO는 현재 AI가 서 있는 위치
위치 주변의 지형만을 모사한 대리 목적 함수(Surrogate Objective Function)를 만듭니다.
복잡한 수학적 계산을 줄이고, 확률적 경사 상승법(Stochastic Gradient Ascent)으로
현재 위치에서 가장 가파른 오르막을 빠르게 찾아냅니다.

핵심 개념 2: 안전한 보폭의 한계선, '클리핑(Clipping)'



- 'Proximal'은 '근접한'이라는 뜻입니다.
- PPO는 새로운 정책이 기존 정책에서 너무 멀어지려 하면, 그 변화량을 일정 범위 내로 잘라냅니다(Clipping).
- 복잡한 연산 없이도 AI가 치명적인 발걸음을 내딛는 것을 원천 차단합니다.

핵심 개념 3: 데이터 재활용을 통한 압도적인 효율성




- 클리핑(Clipping)이라는 강력한 안전망이 있기 때문에, PPO는 획득한 데이터를 한 번 쓰고 버리지 않습니다.
- 동일한 경험 데이터를 재사용하여 여러 번의 미니배치 업데이트 (Multiple Epochs)를 수행합니다.
- 결과적으로 적은 경험으로도 더 많은 것을 배우는 뛰어난 데이터 효율성(Sample Complexity)을 달성합니다.

PPO의 끊임없는 무한 피드백 루프

1단계: 환경 탐험
(Sampling Data)



2단계: 정책 최적화
(Optimizing Surrogate)



PPO는 두 가지 과정을 끊임없이 교차(Alternate)하며 진화합니다.
환경과 상호작용하며 데이터를 수집하고, 대리 목적 함수를 최적화하며 안전 구역 내에서
정책을 업데이트합니다. 이 유연한 루프 덕분에 범용성을 갖춥니다.


정책 최적화 알고리즘의 진화 매트릭스

	Standard PG	TRPO	PPO
구현 단순성 (Simplicity)	●	○	●
데이터 효율성 (Sample Complexity)	○	●	●
업데이트 안전성 (Safety)	○	●	●
학습 속도 (Wall-time)	◐	○	●


PPO는 과거 알고리즘들이 겪던 양자택일의 딜레마를 완벽하게 해결했습니다.

시뮬레이션 로봇부터 아케이드 게임까지, 현실 세계의 증명

논문의 실험 결과는 PPO의 범용성을 명확히 입증했습니다.



로봇 보행 제어 (Robotic Locomotion):
복잡하고 연속적인 물리적 움직임을
안정적으로 학습.




아타리 게임 (Atari Games):
직관적이지 않은 다양한 환경에서도
다른 알고리즘을 압도하는 성능 기록.

PP0가 달성한 ‘마법의 삼각형’

원논문의 결론이 말하듯,
PP0의 진정한 가치는 어느 한 가지
지표에서 1등을 한 것이 아닙니다.

데이터 효율성, 구조의 단순화,
그리고 실제 학습 소요 시간(Wall-time)
간의 가장 이상적인
균형(Favorable Balance)을
완벽하게 찾아낸 데 있습니다.



현대 인공지능을 완성한 가장 신뢰할 수 있는 나침반

2017년에 발표된 PPO는 단순히 우수한 알고리즘을 넘어
넘어 현대 AI 발전의 표준으로 자리 잡았습니다.

현재 우리가 매일 사용하는 ChatGPT와 같은
대규모 언어 모델(LLM)이 인간의 의도에 맞게 학습하는
과정(RLHF)의 핵심 엔진 역시 바로 이 PPO입니다.

가장 단순한 제약(Clippling)으로 가장 위대한 도약을 이뤄낸 PPO의 여정은 지금도 계속되고 있습니다.